XÂY DỰNG CHATBOT CHĂM SÓC KHÁCH HÀNG BẰNG PHƯƠNG PHÁP FINETUNED MODEL LLAMA 3.2 VÀ TÍCH HỢP KỸ THUẬT RAG TỐI ƯU TRUY VẤN ỨNG DỤNG TẠI NHÀ HÀNG KIMOCHI SUSHI

Abstract

Trong bối cảnh số hóa dịch vụ ẩm thực, Kimochi Sushi phát triển một hệ thống ***chatbot chăm sóc khách hàng*** *nhằm tư vấn thực đơn và hỗ trợ trải nghiệm tại nhà hàng. Giải pháp được xây dựng trên nền tảng* ***LLAMA 3.2–1B*** *và tinh chỉnh bằng hơn* ***7.000 sample cặp hội thoại*** *dựa trên thông tin dữ liệu từ nhà hàng Kimochi như thực đơn, thông tin nhà hàng, tuyển dụng,... với sự hỗ trợ của các mô hình ngôn ngữ lớn như ChatGPT và Gemini tạo ra, sau đó được đánh giá, chỉnh sửa để đảm bảo tính chính xác, đầy đủ và phù hợp văn phong chuẩn chăm sóc khách hàng. Hệ thống còn kết hợp* ***kỹ thuật RAG*** *với kho dữ liệu lưu trữ trên* ***Qdrant Cloud,*** *hệ thống phân hai trường hợp gồm tìm kiếm* ***câu tương đồng*** *với và* ***tìm kiếm keyword, Hydrib*** *dựa trên cơ sở dữ liệu được embedding các tài liệu và bộ dữ liệu training mô hình. Với giải pháp này giúp tối ưu được hiệu quả , thời gian và tính chính xác trong quá trình truy vấn, đồng thời duy trì khả năng phản hồi linh hoạt khi gặp câu hỏi mới. Kết quả đánh giá cho thấy mô hình tùy chỉnh của Kimochi đạt chất lượng vượt trội so với phiên bản gốc thông qua các thước đo* ***ROUGE*** *và* ***BERTScore****. Ứng dụng này không chỉ giúp khách hàng tiếp cận thông tin về món ăn một cách tự nhiên, chính xác mà còn mở ra triển vọng ứng dụng AI cá nhân hóa trong ngành F&B.*

Từ khóa: Chatbot; RAG; LLAMA 3; Qdrant; BERTScore; Cá nhân hóa; Ẩm thực Nhật.

1. Đặt vấn đề

Sự cạnh tranh ngày càng gay gắt trong ngành dịch vụ ăn uống đặt ra yêu cầu cao về tốc độ và chất lượng chăm sóc khách hàng. Ngoài việc mang đến những món ăn ngon, nhà hàng hiện nay cần có khả năng phản hồi thắc mắc, xử lý vấn đề và cung cấp thông tin kịp thời cho thực khách. Trong bối cảnh đó, sự phát triển của các mô hình trí tuệ nhân tạo thế hệ mới, điển hình là **LLAMA 3.2–1B**, mở ra cơ hội tạo dựng các hệ thống hỗ trợ khách hàng hiệu quả hơn so với phương thức truyền thống vốn phụ thuộc nhiều vào nhân lực.

Xuất phát từ nhu cầu thực tiễn, nhóm thực hiện đã phát triển một **chatbot dành riêng cho Kimochi Sushi**, được tinh chỉnh từ LLAMA 3.2–1B và huấn luyện trên tập dữ liệu hội thoại chuyên biệt xoay quanh thực đơn, nguyên liệu và dịch vụ tại nhà hàng. Bên cạnh đó, hệ thống được tăng cường bằng công nghệ **RAG** kết hợp với kho dữ liệu **Qdrant**

Cloud, cho phép chatbot không chỉ truy xuất thông tin chính xác mà còn phản hồi một cách tự nhiên và linh hoạt với những câu hỏi chưa từng gặp trước đây.

Chatbot tại Kimochi Sushi được thiết kế với mục tiêu trọng tâm là **giải đáp thắc mắc và hỗ trợ chăm sóc khách hàng trong các vấn đề liên quan dịch vụ, trao đổi với khách thông qua Fanpage**. Hệ thống có thể cung cấp thông tin về thực đơn, gợi ý món ăn phù hợp, hỗ trợ đặt bàn và phản hồi kịp thời các vấn đề phát sinh. Cách tiếp cận này không chỉ giúp giảm tải cho nhân viên, đảm bảo tính nhất quán trong tư vấn, mà còn mang đến sự tiện lợi và hài lòng cho thực khách. Kết quả đánh giá qua các thước đo như **ROUGE** và **BERTScore** cho thấy mô hình LLAMA 3.2–1B sau khi tùy chỉnh đạt hiệu quả cao hơn bản gốc, chứng minh tính khả thi của việc ứng dụng AI trong chăm sóc khách hàng. Đồng thời, nghiên cứu cũng mở ra hướng phát triển các giải pháp chatbot cá nhân hóa trong ngành F&B trong tương lai.

2. Cơ sở lý thuyết

2.1. Lý thuyết đề tài

Ngành công nghiệp ẩm thực đang trải qua một sự chuyển đổi mạnh mẽ với sự tích hợp ngày càng sâu rộng của Trí tuệ Nhân tạo (AI) vào quy trình phục vụ và nâng cao trải nghiệm khách hàng. Trong bối cảnh cạnh tranh này, nhà hàng Kimochi Sushi đối mặt với những thách thức đặc thù đòi hỏi giải pháp công nghệ vượt trội.

Ba vấn đề cốt lõi cần được giải quyết bao gồm: Thứ nhất, nhu cầu cung cấp thông tin chính xác, nhanh chóng và đầy đủ về thực đơn độc quyền kết hợp tinh hoa ẩm thực Nhật Bản và Việt Nam. Đây là một hệ thống món ăn phức tạp với nguyên liệu đa dạng và kỹ thuật chế biến đặc thù, đòi hỏi sự giải thích chi tiết. Thứ hai, việc cập nhật và truyền tải kịp thời các chính sách khuyến mãi, chương trình ưu đãi luôn thay đổi theo ngày hoặc sự kiện là một hạn chế lớn của các hệ thống thông thường, dẫn đến trải nghiệm khách hàng không đồng nhất. Thứ ba, rủi ro từ hiện tượng "ảo giác" (hallucination) của các mô hình ngôn ngữ lớn (LLM) thuần túy – tức khả năng sinh ra thông tin sai lệch, không có thực hoặc không phù hợp với thực tế kinh doanh – là mối đe dọa trực tiếp đến uy tín và chất lượng dịch vụ của nhà hàng.

Xuất phát từ những yêu cầu thực tiễn cấp thiết này, giải pháp kỹ thuật kết hợp phương pháp RAG (Retrieval-Augmented Generation) với mô hình ngôn ngữ lớn Llama 3.2-1B được tinh chỉnh bằng kỹ thuật LoRA (Low-Rank Adaptation) đã được đề xuất. Bản chất đột phá của RAG nằm ở cơ chế bổ sung tri thức động và đảm bảo tính xác thực. Thay vì dựa hoàn toàn vào kiến thức được học trước đó (có thể lỗi thời hoặc không đủ chuyên sâu) của LLM, hệ thống luôn ưu tiên truy vấn và truy xuất dữ liệu nghiệp vụ mới nhất, cụ thể từ một cơ sở dữ liệu vector chuyên dụng sử dụng Qdrant.

Cơ sở dữ liệu này đóng vai trò là kho lưu trữ toàn diện, bao gồm chi tiết toàn bộ thực đơn lai (mô tả, thành phần, giá cả), các chương trình khuyến mãi đang áp dụng, chính sách đặt bàn và các quy trình nghiệp vụ nội bộ liên quan. Chỉ sau khi có được ngữ cảnh chính xác và cập nhật từ dữ liệu được truy xuất, LLM mới được kích hoạt để xử lý các truy vấn phức tạp hơn như gợi ý món ăn dựa trên sở thích cá nhân, tình trạng dị ứng, ngân sách, hoặc giải thích kỹ thuật chế biến đặc biệt của các món lai.

Cơ chế hai bước (truy xuất rồi sinh) này tạo thành nền tảng vững chắc. Nó đảm bảo độ chính xác tuyệt đối của thông tin cốt lõi (giá cả, thành phần, khuyến mãi, chính sách) đồng thời vẫn duy trì và tận dụng được khả năng xử lý ngôn ngữ tự nhiên linh hoạt, gần gũi và thông minh của LLM. Điều này đặc biệt quan trọng đối với một mô hình ẩm thực lai như Kimochi Sushi, nơi đòi hỏi sự giải thích rõ ràng, hấp dẫn về nguồn gốc nguyên liệu, sự kết hợp hương vị độc đáo Nhật-Việt, và quy trình chế biến tinh tế – những yếu tố vượt ra ngoài khả năng đơn thuần của một cơ sở dữ liệu thông thường hay một chatbot cứng nhắc chỉ dựa trên kịch bản có sẵn.

2.2. Một số dự án liên quan

Nền tảng lý thuyết và kiến trúc cốt lõi của RAG được thiết lập vững chắc bởi công trình nghiên cứu tiên phong của Lewis và cộng sự vào năm 2020. Nhóm nghiên cứu này đã đề xuất một kiến trúc RAG hiện đại bằng cách kết hợp hiệu quả hai thành phần chính: một hệ thống truy xuất thông tin dựa trên mô hình DPR (Dense Passage Retriever) để tìm kiếm các đoạn văn bản liên quan từ một kho tài liệu lớn, và một mô hình sinh ngôn ngữ (BART) để tạo ra câu trả lời dựa trên thông tin truy xuất được.

Đặc biệt, Lewis và cộng sự giới thiệu hai cơ chế sinh đáp án mang tính đột phá: RAG-Sequence và RAG-Token. RAG-Sequence sinh toàn bộ câu trả lời dựa trên một ngữ cảnh cố định duy nhất được truy xuất, đảm bảo tính nhất quán cao. Trong khi đó, RAG-Token linh hoạt hơn, cho phép tham chiếu đến các ngữ cảnh khác nhau cho *mỗi token* (đơn vị từ) trong quá trình sinh câu trả lời, giúp xử lý tốt hơn các câu hỏi yêu cầu tổng hợp thông tin từ nhiều nguồn. Hai cơ chế này đại diện cho những cách tiếp cận bổ sung nhằm cân bằng giữa tính nhất quán và khả năng thích ứng đa ngữ cảnh.

Sự phát triển và hệ thống hóa của kỹ thuật RAG tiếp tục được đẩy mạnh, thể hiện rõ qua phân loại của Gao và cộng sự (2024). Phân loại này làm nổi bật sự tiến hóa của RAG qua ba thế hệ chính:

- Naive RAG: Là mô hình cơ bản nhất với quy trình truy xuất -> sinh đáp án đơn giản, dễ triển khai. Tuy nhiên, nó có thể gặp hạn chế về độ chính xác (nếu truy xuất kém) và khả năng phù hợp ngữ cảnh sâu.
- Advanced RAG: Tích hợp các kỹ thuật nâng cao quan trọng như *sắp xếp lại (re-ranking)* kết quả truy xuất để chọn lọc thông tin tốt nhất, và *truy xuất đa*

bước (multi-hop retrieval) cho các câu hỏi yêu cầu suy luận qua nhiều nguồn thông tin hoặc bước logic.

- Modular RAG: Đại diện cho hướng tiếp cận tối ưu và linh hoạt nhất. Kiến trúc được *module hóa* rành mạch, tách biệt ba thành phần chính: Truy xuất (Retriever), Sinh câu trả lời (Generator), và Tăng cường/Kiểm soát (Augmenter/Controller). Điều này cho phép tùy chỉnh, thay thế hoặc tối ưu từng module độc lập dễ dàng.

Trên thực tế, tính ứng dụng rộng rãi và hiệu quả của RAG đã được chứng minh qua nhiều dự án triển khai gần đây trong các lĩnh vực đa dạng. Ví dụ điển hình là hệ thống hỗ trợ nạn nhân quấy rối trực tuyến do Vakayil phát triển (2024). Hệ thống này sử dụng RAG kết hợp LLM (Llama 2) để cung cấp thông tin pháp lý chính xác, nguồn lực hỗ trợ và hướng dẫn hành động phù hợp dựa trên cơ sở dữ liệu cập nhật về luật pháp và dịch vụ hỗ trợ.

Một ví dụ khác là chatbot giáo dục dự đoán điểm chuẩn đại học của Thamilselvan (2024). Chatbot này tận dụng RAG và LLM (cũng thường là Llama 2) để truy xuất dữ liệu tuyển sinh mới nhất, phân tích xu hướng điểm các năm trước, và sinh lời giải thích cá nhân hóa về cơ hội trúng tuyển cho thí sinh dựa trên điểm thi và nguyện vọng của họ. Cả hai hệ thống này đều khẳng định giá trị của việc bổ sung nguồn tri thức bên ngoài động cho LLM để xử lý các nghiệp vụ chuyên sâu, đòi hỏi thông tin cập nhật và chính xác cao.

Riêng trong lĩnh vực Dịch vụ ăn uống (F&B), dự án chatbot dịch vụ khách hàng của Wangsa (2024) cung cấp bài học kinh nghiệm thực tiễn quý giá. Dự án này nhấn mạnh tầm quan trọng sống còn của việc thiết kế một quy trình làm việc (workflow) tối ưu hóa cho ngành. Hai yêu cầu được đặt lên hàng đầu là tốc độ phản hồi nhanh chóng (dưới 3 giây) để không làm gián đoạn trải nghiệm khách hàng, và độ chính xác tuyệt đối của thông tin menu (giá cả, mô tả, tình trạng món) để tránh nhầm lẫn và khiếu nại. Những yêu cầu và kinh nghiệm triển khai này hoàn toàn phù hợp và có thể được Kimochi Sushi kế thừa, áp dụng một cách hiệu quả vào việc phát triển trợ lý ảo chuyên sâu của mình. Các dự án này không chỉ minh họa tính linh hoạt và hiệu quả của RAG trong các ngữ cảnh thực tế mà còn cung cấp các bài học thiết thực về triển khai để đạt được hiệu suất cao và độ tin cậy trong môi trường kinh doanh đòi hỏi khắt khe.

3. Phương pháp nghiên cứu

3.1. Tập dữ liệu

Nhóm đã chủ động lựa chọn một chiến lược tiếp cận mang tính đặc thù, thay vì đi theo xu hướng phổ biến là sử dụng các kho dữ liệu hội thoại công khai. Những kho

dữ liệu có sẵn trên mạng, mặc dù phong phú về số lượng và đa dạng về chủ đề, nhưng hầu hết lại tập trung vào các ngữ cảnh giao tiếp mang tính chung chung, xa rời đặc thù của ngành dịch vụ ẩm thực. Do đó, nếu áp dụng trực tiếp, chúng sẽ khó đảm bảo rằng mô hình chatbot sau huấn luyện có thể phản hồi đúng bối cảnh và thỏa mãn kỳ vọng của khách hàng trong môi trường nhà hàng thực tế. Để khắc phục hạn chế này, nhóm nghiên cứu đã lựa chọn hướng tiếp cận chủ động: tự thiết kế và thu thập dữ liệu mới, trong đó mọi thành phần đều được xây dựng dựa trên môi trường ứng dụng cụ thể tại Kimochi Sushi. Cách làm này không chỉ giúp đảm bảo độ gắn kết với ngữ cảnh triển khai thực tế, mà còn góp phần nâng cao chất lượng của phản hồi, khiến hệ thống trở nên tự nhiên, gần gũi và hữu ích hơn, thay vì đưa ra những câu trả lời thiên về tính lý thuyết hoặc vượt ngoài phạm vi cần thiết.

Nguồn dữ liệu phục vụ cho việc huấn luyện được hình thành trên cơ sở khai thác những thông tin chính thống do phía Kimochi Sushi trực tiếp cung cấp. Cụ thể, các nguồn này bao gồm: thực đơn món ăn được cập nhật định kỳ; bảng mô tả chi tiết hương vị nhằm truyền tải sự khác biệt và đặc trưng của từng món; các tài liệu giới thiệu nhà hàng phục vụ cho mục đích quảng bá và truyền thông thương hiệu; thông tin tuyển dụng phản ánh nhu cầu nhân sự trong thực tế; cùng với đó là những buổi trao đổi trực tiếp với quản lý nhà hàng nhằm bổ sung các tình huống đặc thù chưa được văn bản hóa. Song song với việc khai thác nguồn tư liệu chính thống, nhóm nghiên cứu còn chú trọng đến việc định hình văn phong hội thoại sao cho phản ánh đúng đặc thù của dịch vụ chăm sóc khách hàng. Để làm được điều này, các mẫu tin nhắn CSKH trên fanpage chính thức của Kimochi Sushi đã được lựa chọn làm nguồn tham chiếu. Việc kế thừa văn phong từ các kênh giao tiếp thực tế không chỉ tạo ra sự đồng bộ trong cách diễn đạt mà còn giúp chatbot duy trì mức độ lịch sự, thân thiện và phù hợp với mong đợi của khách hàng.



Hình 3.1.1: Menu ở Kimochi Sushi

STT	Câu Hỏi	Câu Trả Lời	Mục Đích Hỏi
1	Menu của bạn nằm ở mức giá nào?	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
2	Cho xem menu nhé	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
3	shop cho e xin menu	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
4	Cho mình xin menu nha	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
5	Em xin menu với ạ	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
6	Cho c xem menu nha	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
7	Gửi c menu nha	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
8	Cho m xin menu nhé	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
9	hi shop em xin menu bên mình với ạ	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
10	xin menu quán ạ	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
11	e xin menu	Dạ em gửi menu ạ, cần tư vấn món ăn Anh/chị nhắn em nha	Xin menu quán
12	Cho xin địa chỉ	Dạ em gửi khách iu địa chỉ các chi nhánh tiệm nhà Chi ạ. Chi nhánh Bình Thạnh: 167/2/5 Ngô Tất Tố, phường Thạnh Mỹ Tây , Thành Phố Hồ Chí Minh. Số Hotline: 0879096969 Chi nhánh Gò Vấp: 590/16 Phan Văn Trị, Phường Hạnh Thông Tây Thành Phố Hồ Chí Minh. Số Hotline: 0888912344 ⏰ Thời gian hoạt động: Mỗi ngày từ 11h đến 22h	địa chỉ quán
13	o dau	Dạ em gửi khách iu địa chỉ các chi nhánh tiệm nhà Chi ạ. Chi nhánh Bình Thạnh: 167/2/5 Ngô Tất Tố, phường Thạnh Mỹ Tây , Thành Phố Hồ Chí Minh. Số Hotline: 0879096969 Chi nhánh Gò Vấp: 590/16 Phan Văn Trị, Phường Hạnh Thông Tây Thành Phố Hồ Chí Minh. Số Hotline: 0888912344 ⏰ Thời gian hoạt động: Mỗi ngày từ 11h đến 22h	địa chỉ quán

Hình 3.1.2: Hỏi đáp từ fanpage cung cấp


```
{
    "Domain": "Đồ uống: Trà Hoa Cúc Táo Đỏ Nóng – Mô tả chung",
    "user_query": "Trà Hoa Cúc Táo Đỏ Nóng là món gì vậy shop?",
    "responses": "Dạ, Trà Hoa Cúc Táo Đỏ Nóng là một thức uống đặc trưng của Kimochi Sushi. Món trà này là sự kết hợp tinh tế giữa vị hoa c
},
{
    "Domain": "Đồ uống: Trà Hoa Cúc Táo Đỏ Nóng – Mô tả chung",
    "user_query": "Trà hoa cúc táo đỏ nóng là món j dzạ?",
    "responses": "Chào bạn, Trà Hoa Cúc Táo Đỏ Nóng là một món trà nóng được pha chế từ hoa cúc chọn lọc và táo đỏ. Hương vị trà ngọt dịu,
},
{
    "Domain": "Đồ uống: Trà Hoa Cúc Táo Đỏ Nóng – Mô tả chung",
    "user_query": "Tra Hoa Cuc Tao Do Nong la mon gi?",
    "responses": "Trà Hoa Cúc Táo Đỏ Nóng là món nước ấm được nhiều khách hàng yêu thích tại Kimochi Sushi ạ. Món này có hương hoa cúc thoa
},
```


Hình 3.1.3: Cấu trúc dữ liệu

Toàn bộ quy trình xây dựng dữ liệu được thiết kế theo hướng hệ thống hóa chặt chẽ, trải qua nhiều vòng rà soát và tinh chỉnh, đảm bảo rằng mỗi mẫu dữ liệu được đưa vào huấn luyện đều có giá trị sử dụng thực tiễn cao. Các bước triển khai cụ thể được mô tả trong Hình 3.1 và có thể tóm lược như sau:

- **Khảo sát nhu cầu thực tế:** Nhóm tiến hành phân tích chi tiết hoạt động vận hành tại nhà hàng để xác định các tình huống giao tiếp thường xuyên phát sinh giữa khách hàng và nhân viên. Các kịch bản được lựa chọn có phạm vi bao phủ rộng, bao gồm đặt bàn, yêu cầu thông tin chi tiết về món ăn, tìm hiểu các chương trình khuyến mãi, xử lý sự cố trong quá trình phục vụ, và tiếp nhận góp ý phản hồi từ thực khách. Đây được xem là bước nền tảng quan trọng, đóng vai trò đảm bảo cho toàn bộ tập dữ liệu phản ánh đúng thực tiễn và bám sát môi trường ứng dụng.

- **Soạn thảo thủ công:** Dựa trên những kịch bản đã xác định, mỗi thành viên trong nhóm trực tiếp soạn thảo bộ câu hỏi – trả lời mẫu. Đặc điểm quan trọng của giai đoạn này là tính đa dạng trong cách diễn đạt: cùng một nội dung nhưng có thể được biểu đạt với nhiều cấp độ lịch sự, nhiều phong cách ngôn ngữ, từ trang trọng đến thân mật. Nhờ vậy, dữ liệu có khả năng mô phỏng được sự phong phú trong giao tiếp thực tế, đồng thời vẫn bảo đảm sự kiểm soát chặt chẽ về chất lượng và tính chính xác.

- **Mở rộng dữ liệu bằng công cụ GenAI:** Sau khi hoàn thiện bộ dữ liệu thủ công ban đầu, nhóm đã tận dụng sức mạnh của các mô hình ngôn ngữ lớn như ChatGPT và Gemini để sinh thêm nhiều biến thể khác nhau của câu hỏi và phản hồi. Tuy nhiên, quá trình này không mang tính tự động hoàn toàn, mà mọi kết quả đầu ra đều phải trải qua bước thẩm định thủ công. Các nội dung không phù hợp hoặc gây nhiễu sẽ bị loại bỏ, trong khi những nội dung có giá trị được chỉnh sửa, tối ưu trước khi đưa vào tập dữ liệu chính thức. Điều này giúp tăng quy mô dữ liệu một cách đáng kể nhưng vẫn duy trì được sự chính xác và nhất quán.

- **Chuẩn hóa và đối chiếu:** Ở bước này, các bộ dữ liệu được biên soạn độc lập bởi từng thành viên được đem ra đối chiếu chéo. Cách làm này vừa giúp loại bỏ sự trùng lặp, vừa phát hiện kịp thời các lỗi ngữ nghĩa, đồng thời giảm thiểu rủi ro thiên lệch do góc nhìn cá nhân. Nhờ đó, dữ liệu trở nên khách quan và toàn diện hơn.

- **Tổng hợp dữ liệu:** Sau khi toàn bộ các bước rà soát và kiểm định được hoàn tất, dữ liệu được hợp nhất thành một tập thống nhất và chuẩn hóa theo một cấu trúc định dạng cố định, đảm bảo sẵn sàng để sử dụng trực tiếp trong giai đoạn huấn luyện mô hình.

Từ quy trình này, nhóm nghiên cứu đã hình thành được hai tập quan trọng:

- **Tập huấn luyện (training set):** Bao gồm hơn 40.000 dòng (hơn 7000 sample gồm các cặp câu hỏi - trả lời) phản ánh đầy đủ các tình huống dịch vụ cơ bản và phổ biến nhất trong bối cảnh nhà hàng. Mỗi mẫu dữ liệu được tổ chức theo cấu trúc *Domain – user_query – response*. Trong đó, Domain biểu thị nhóm tình huống dịch vụ như đặt bàn, gọi món hay khuyến mãi; user_query mô phỏng các biến thể câu hỏi thực tế mà khách hàng có thể sử dụng; và response thể hiện phản hồi từ hệ thống theo đúng phong cách CSKH của Kimochi Sushi. Để đa dạng hóa hơn nội dung các vấn đề trong tập huấn luyện, chúng tôi phát triển với mỗi nội dung hỏi-đáp sẽ phân thành 3 bộ QA với cách hỏi và trả lời khác nhau nhưng vẫn đảm bảo thống nhất về nội dung, tính chính xác và đầy đủ cũng như khác về văn phong. Đây chính là bộ dữ liệu nền tảng, bảo đảm rằng chatbot có thể xử lý thành công hầu hết các yêu cầu điển hình từ phía khách hàng.

- **Tập kiểm tra (test set):** Gồm khoảng 5.000 dòng (hơn 700 sample gồm các cặp câu hỏi - trả lời), được xây dựng hoàn toàn độc lập với tập huấn luyện. Khác biệt nổi bật của tập kiểm tra là sự xuất hiện của các biến thể ngữ nghĩa mới và những tình huống chưa từng được mô hình tiếp xúc trong quá trình học. Điều này cho phép đánh giá chính xác hơn khả năng khái quát hóa và mức độ bền vững của mô hình khi gặp phải những truy vấn mới trong thực tế triển khai.

Kết quả cuối cùng của toàn bộ quá trình trên là một hệ thống dữ liệu vừa có quy mô lớn, vừa có tính đặc thù cao, bao gồm một tập huấn luyện đồ sộ kết hợp với một tập kiểm tra độc lập. Sau khi được sử dụng để tiến hành tinh chỉnh (fine-tuned), phiên bản tùy chỉnh của LLaMA 3.2–1B đã chứng minh được sự vượt trội rõ rệt so với mô hình gốc. Cụ thể, chatbot không chỉ cải thiện đáng kể về độ tự nhiên trong câu trả lời mà còn thể hiện khả năng duy trì mạch hội thoại liền lạc và phản hồi sát ngữ cảnh, đáp ứng tốt yêu cầu xử lý các tình huống đa dạng trong môi trường dịch vụ nhà hàng.

3.2. Quá trình fine-tuned mô hình LLAMA 3.2.

Toàn bộ quá trình **fine-tunend** được triển khai trên một **tập dữ liệu** với quy mô hơn **7.000 sample cặp QA hội thoại**, được biên soạn thủ công dựa trên các tình huống thực tế tại **Nhà hàng Kimochi Sushi**. Nội dung hội thoại bao quát nhiều khía cạnh đa dạng: từ **tuyển dụng**, **chế độ lương thưởng**, **ca làm việc**, **quy trình ứng tuyển**, cho đến các nghiệp vụ **tư vấn món ăn trong thực đơn**, **hỗ trợ đặt bàn trực tiếp hoặc trực tuyến**, **xử lý sự cố trong quá trình phục vụ**, **tiếp nhận và phản hồi góp ý từ khách hàng**, cũng như các tình huống liên quan đến **chương trình khuyến mãi** và **chăm sóc khách hàng thân thiết**. Tập dữ liệu được tổ chức theo cấu trúc *Domain – user_query – response*, nhờ đó mô hình có thể vừa xác định chính xác miền tri thức, vừa duy trì sự thống nhất trong phong cách diễn đạt, từ đó tạo ra phản hồi **tự nhiên, thân thiện và phù hợp với bối cảnh dịch vụ ẩm thực**.

Mô hình nền được sử dụng là **LLaMA-3.2-1B-Instruct**, vốn đã trải qua giai đoạn **pre-training** trên tập dữ liệu ngôn ngữ quy mô lớn. Nhờ vậy, mô hình sở hữu khả năng **hiểu ngôn ngữ mạch lạc**, xử lý chính xác về **cú pháp – ngữ pháp**, đồng thời tích lũy một **nguồn tri thức nền phong phú**. Đây chính là nền tảng quan trọng để tinh chỉnh chuyên biệt cho nhu cầu **hỗ trợ khách hàng** của Kimochi Sushi. Việc tải và triển khai mô hình được thực hiện thông qua **Hugging Face**, với tài khoản xác thực để đảm bảo **tính ổn định trong truy cập** cũng như **đồng bộ tokenizer và checkpoint mô hình** trong giai đoạn ứng dụng thực tế.

Trong quá trình fine-tuning, nhóm không huấn luyện lại toàn bộ mô hình gốc mà áp dụng kỹ thuật **LoRA (Low-Rank Adaptation)**. Cách tiếp cận này chỉ thêm một lượng nhỏ tham số vào các lớp được chọn, trong khi phần lớn trọng số ban đầu được giữ nguyên. Điều này giúp **tiết kiệm tài nguyên tính toán và bộ nhớ**, đồng thời vẫn đảm bảo bảo toàn tri thức nền, chỉ bổ sung thêm kiến thức liên quan đến **dịch vụ khách hàng trong ngành ẩm thực**. Sau khi chuẩn bị, tập dữ liệu được **chuẩn hóa sang chat template** và tiếp tục được **mã hóa thành token ID** trước khi đưa vào huấn luyện. Trong toàn bộ quá trình tối ưu, chỉ những tham số mới từ **LoRA** được cập nhật, giúp mô hình **hội tụ nhanh** và hạn chế hiện tượng **overfitting**.

Các **siêu tham số (hyperparameters)** trong huấn luyện được cấu hình cụ thể như sau: **learning rate = 1e-5**, **batch size = 8**, **số epoch = 3**, kết hợp với **linear scheduler** và **500 bước warmup** để khởi động ổn định. Thay vì để mô hình dừng sớm theo cơ chế mặc định, nhóm thiết lập **max_steps = 7.352** nhằm đảm bảo quá trình huấn luyện đi trọn vẹn số vòng lặp cần thiết. Bên cạnh đó, tiến trình được giám sát thông qua **logging_steps = 10**, toàn bộ log được lưu trên **TensorBoard**, và mô hình được lưu sau mỗi **700 bước**. Cơ chế **save_total_limit = 2** giúp kiểm soát dung lượng lưu trữ, trong khi **load_best_model_at_end = True** đảm bảo rằng phiên bản có **eval_loss thấp nhất** sẽ được chọn làm mô hình cuối cùng. Đặc biệt, việc sử dụng **fp16 (mixed precision training)** giúp giảm áp lực bộ nhớ GPU và tăng tốc độ xử lý, phù hợp với điều kiện tài nguyên hạn chế.



Hình 3.2: Biến động Training Loss trong fine-tuned mô hình với tập dữ liệu 40.000 dòng

Kết quả huấn luyện cho thấy **training loss** giảm đều theo từng epoch. Ở giai đoạn đầu, loss giảm nhanh, phản ánh khả năng tiếp nhận đặc trưng dữ liệu tốt. Sang các epoch sau, đường cong loss dần ổn định và hội tụ quanh một giá trị thấp, chứng tỏ mô hình đã đạt **trạng thái tối ưu**, không xuất hiện dao động lớn.

Sau giai đoạn huấn luyện, mô hình được kiểm tra trên một **tập dữ liệu thử nghiệm độc lập** gồm khoảng **5.000 dòng hội thoại mới**, hoàn toàn không trùng lặp với dữ liệu huấn luyện. Việc đánh giá được triển khai theo hai hướng song song. Về **định lượng**, nhóm sử dụng các chỉ số **ROUGE-1, ROUGE-2, ROUGE-Lsum** để đo mức độ trùng khớp từ vựng, kết hợp cùng **BERTScore** nhằm phản ánh mức độ tương đồng ngữ nghĩa. Song song đó, về **định tính**, mô hình được đánh giá thủ công dựa trên các khía cạnh như **tính chính xác**, **mức độ tự nhiên**, **sự lịch sự trong đối thoại**, và **khả năng duy trì ngữ cảnh**.

Kết quả phân tích cho thấy phiên bản mô hình sau tinh chỉnh không chỉ đạt **điểm số nổi bật trên các thước đo khách quan**, mà còn được ghi nhận tích cực trong quá trình đánh giá thủ công. Mô hình thể hiện khả năng **duy trì mạch hội thoại liền mạch**, **ứng biến linh hoạt trước nhiều tình huống khác nhau**, đồng thời cung cấp phản hồi mang tính **gần gũi, chuyên nghiệp và phù hợp với môi trường dịch vụ nhà hàng**.

3.3. Kỹ thuật RAG

4. Kết quả nghiên cứu

Chúng tôi đã xây dựng tập dữ liệu tùy chỉnh gồm các bộ câu hỏi và trả lời với các thông tin về thực đơn, dịch vụ, thông tin chung và các tình huống xử lý vấn đề với khách hàng từ nguồn tài liệu, thông tin nhà hàng Kimochi Sushi cung cấp. Tập dữ liệu được chia hai phần gồm: Tập huấn luyện được tạo bằng sự hỗ trợ của các mô hình ngôn ngữ lớn (LLM) dựa trên các tài liệu, thông tin của Kimochi Sushi và tập kiểm thử được xây dựng riêng dựa trên các nội dung huấn luyện cho mô hình, đảm bảo tính khách quan cho quá trình huấn luyện.

4.1. Kết quả kiểm thử mô hình fine-tuned

Với tập dữ liệu huấn luyện, chúng tôi đã xây dựng được hơn 8000 sample với đồ dài 40852 dòng bao gồm các cặp câu hỏi - trả lời tương tự như tin nhắn thật giữa khách hàng và nhân viên, được lấy tham khảo văn phong từ bộ tin nhắn trên Fanpage Kimochi Sushi. Cấu trúc tập dữ liệu gồm Domain - chứa chủ đề hội thoại, user_query - chứa câu hỏi và responses - chứa nội dung câu trả lời. Bên cạnh đó với mỗi nội dung vấn đáp, chúng tôi phát triển thành 3 bộ câu hỏi với cách hỏi và trả lời khác nhau nhưng đảm bảo chính xác cũng như đồng nhất về nội dung.

Sau khi huấn luyện mô hình, chúng tôi tiến hành kiểm tra trên tập kiểm thử với kích cỡ hơn 800 cặp câu hỏi - trả lời và độ dài 4183 dòng. Kết quả đánh giá được chúng tôi quyết định dựa trên các chỉ số Precision, Recall, F1-score với ROUGE-1, ROUGE-2, ROUGE-L, GOUGE-L-SUM và BERTScore của mô hình finetuned. Sau đó được so sánh với mô hình gốc để đánh giá sự cải thiện, tối ưu của mô hình finetuned chúng tôi.

Dưới đây là kết quả đánh giá mô hình fine-tuned trên tập dữ liệu của chúng tôi.

Bảng 1. Bảng thống kê kết quả đánh giá mô hình fine-tuned với các giá trị Precision, Recall và F1 dựa trên các chỉ số ROUGE và BERTScore.

	Precision	Recall	F1
ROUGE 1	0.1146	0.6653	0.1898
ROUGE 2	0.0466	0.2702	0.0771
ROUGE L	0.0775	0.4621	0.1287
ROUGE L-SUM	0.0833	0.4885	0.1381
BERTScore	0.6840	0.8180	0.7430

4.2. So sánh các chỉ số đánh giá giữa mô hình fine-tuned với mô hình gốc

Sau khi đánh giá mô hình fine-tuned, chúng tôi tiến hành chạy kiểm thử trên mô hình gốc với cùng tập dữ liệu kiểm thử và tính toán các chỉ số tương tự. Dưới đây là kết quả thống kê các chỉ số đánh giá giữa mô hình finetuned và mô hình gốc

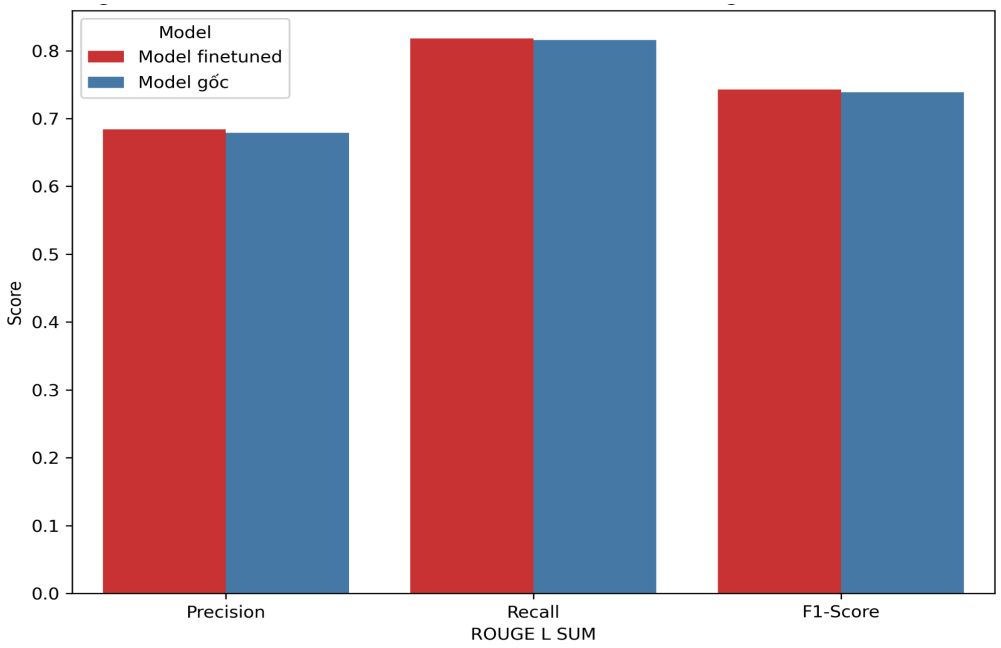
Bảng 2. Bảng thống kê các chỉ số đánh giá Precision, Recall và F1 dựa trên các giá trị ROUGE giữa mô hình fine-tuned và mô hình gốc.

	Chỉ số	Precision	Recall	F1
Mô hình LLAMA 332 Finetuned	**ROUGE 1**	0.1146	0.6653	0.1898
	ROUGE 2	0.0466	0.2702	0.0771
	ROUGE L	0.0775	0.4621	0.1287
	ROUGE L-SUM	0.0833	0.4885	0.1381
Mô hình LLAMA 3.2 gốc	**ROUGE 1**	0.1100	0.6393	0.1819
	ROUGE 2	0.0444	0.2577	0.0733
	ROUGE L	0.0740	0.4425	0.1228
	ROUGE L-SUM	0.0802	0.4687	0.1326

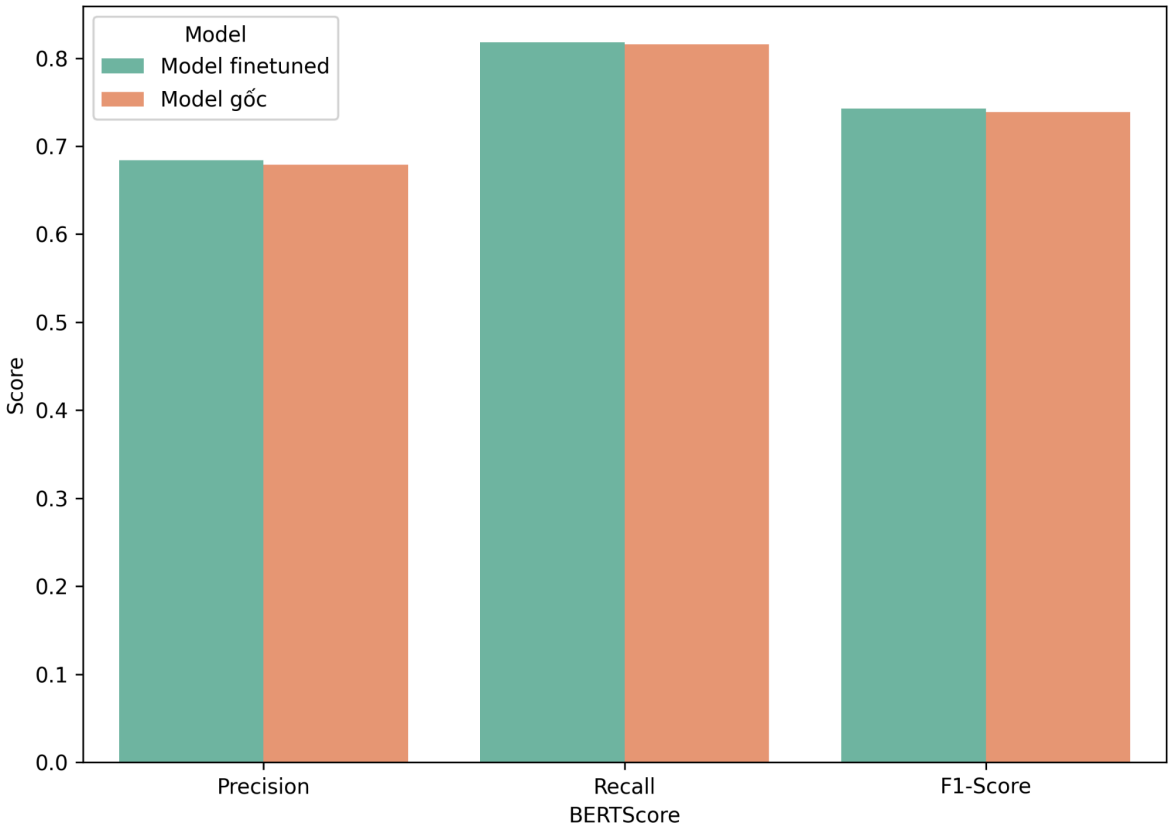
Bảng 3: So sánh các giá trị BERTScore giữa mô hình fine-tuned và mô hình gốc

	BERTScore Precision	BERTScore Recall	BERTScore F1
Mô hình LLAMA 3.2 Fine-tuned	0.6840	0.8180	0.7430

Mô hình LLAMA 3.2 gốc	0.6791	0.8155	0.7390



Hình 4.2.1. Biểu đồ so sánh giá trị ROUGE L SUM dựa trên các chỉ số Precision, Recall và F1-Score giữa mô hình finetuned và mô hình gốc



Hình 4.2.2. Biểu đồ so sánh giá trị BERTScore theo các chỉ số Precision, Recall và F1-Score giữa mô hình finetuned và mô hình gốc

4.3. Kết quả so sánh các model embedding.

4.4. Kết quả kiểm thử và đánh giá trên giao diện Chatbot

Để có thể nhìn nhận rõ ràng trong việc đưa ra các đánh giá của kết quả, giá trị từ câu hỏi khách hàng thông qua ChatBot, chúng tôi đã trực quan hóa, tiến hành thiết lập giao diện cơ bản cho sản phẩm bằng thư viện Gradio. Và để nâng cao trải nghiệm của khách hàng khi sử dụng Chatbot, Chúng tôi đã tích hợp kỹ thuật RAG vào mô hình nhằm nâng cao thời gian truy vấn thông tin.



Hình 4.4.1: Giao diện Chatbot thử nghiệm bằng Gradio

Sau khi triển khai giao diện, chúng tôi thực hiện hỏi đáp với Chatbot về các câu hỏi thông tin về món ăn một cách ngẫu nhiên để đánh giá hiệu suất và chất lượng câu trả lời.



Hình 4.4.2: Kiểm thử Chatbot với các truy vấn thực tế

Theo đánh giá khả năng phản hồi của mô hình sau khi fine-tuned và tích hợp RAG, chúng tôi chia thành hai nhóm thử nghiệm:

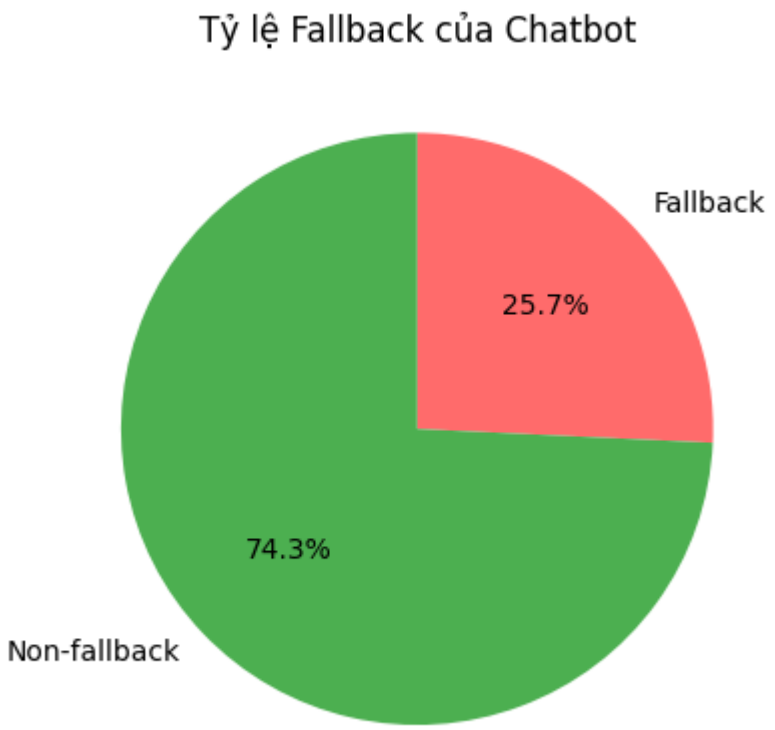
- **Nhóm thứ nhất** là nhóm nội bộ trong dự án, do các thành viên đã trực tiếp phát triển nên các hỏi đã đưa ra đều có chủ đích, có tính bao phủ đa dạng các loại truy vấn ví dụ như thành phần món, so sánh giữa các món,... nhằm để kiểm tra mô hình có học tốt hay không, việc Chatbot đưa ra những câu trả lời đúng,

đầy đủ, rõ ràng thông tin cần. Nhưng trong lúc đánh giá, chúng tôi đã phát hiện ra Chatbot gặp khó khăn khi trả lời các câu hỏi có tính multi-turn (câu hỏi nối tiếp có ngữ cảnh). Đây cũng là nhược điểm thường gặp ở nhiều mô hình hiện nay.

- **Nhóm thứ hai**, nhóm khách hàng thực tế sẽ đưa ra câu hỏi tự nhiên, ngẫu nhiên hơn. Đối với câu hỏi khách hàng thường câu hỏi trước và câu hỏi sau đề có liên hệ với nhau nên Chatbot nên kết qua đánh giá Chatbot . Kết quả tích cực chứng minh chatbot không bị "overfitting" (học vẹt) vào dữ liệu train, mà có tính ứng dụng cao. Các góp ý (cần mở rộng dữ liệu đa dạng hơn, nhớ ngữ cảnh hội thoại) là rất thực tế, chỉ ra hướng cải tiến.
-

Một số đánh giá tổng quát Chatbot sau khi thu thập đánh giá từ hai nhóm thực nghiệm

- **Nội dung tư vấn:** Khá chính xác đối với dữ liệu đã huấn luyện, nhưng một số câu hỏi không được huấn luyện trả lời vẫn còn thiếu rõ ràng.
- **Tốc độ tư vấn:** Được cải thiện nhờ RAG, trung bình từ 3 - 5 giây, đáp ứng gần thời gian thực.
- Tính liên kết ngữ cảnh: hạn chế trong các hội thoại đa lượt, mô hình dễ "quên" thông tin từ câu hỏi trước.
- **Khả năng xử lý lỗi:** Có khả năng fallback (trả lời mặc định) khi gặp câu hỏi ngoài phạm vi, nhưng tỉ lệ fallback vẫn cần tối ưu thêm.
- **Tỷ lệ fallback** chúng tôi đã tính dựa trên **300 câu hỏi** tự nhiên của khách hàng, chúng tôi đã tiến hành kiểm tra. Kết quả cho thấy Chatbot có 74.3% lượt trả lời không rơi vào fallback, nghĩa là trong đa số trường hợp, hệ thống vẫn đưa ra phản hồi thay vì "xin lỗi/không hiểu". Tuy nhiên, vẫn còn 25.7% lượt trả lời rơi vào fallback, tức là cứ 4 câu hỏi thì có 1 câu chatbot trả ra là không trả lời được đúng trọng tâm.



Hình 4.4.3 : Biểu đồ tròn hiển thị tỷ lệ Fallback của Chatbot

=> Tỷ lệ này cho thấy Chatbot có khả năng sử dụng được, nhưng chưa ổn định, cần giảm fallback xuống mức <10% để ứng dụng thực tế. Con số 25% phản ánh độ bao phủ dữ liệu train chưa đủ hoặc khả năng xử lý ngữ cảnh còn yếu.

5. Kết luận

Với những gì chúng tôi đã nghiên cứu, thử nghiệm và triển khai thành công trong việc xây dựng mô hình Chatbot tư vấn và phản hồi về nhu cầu hiểu rõ thông tin nhà hàng, quy định, tin tuyển dụng, các câu hỏi về các món ăn của nhà hàng, dựa vào kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) và tích hợp kỹ thuật Retrieval-Augmented Generation (RAG) trên nền tảng ngôn ngữ lớn LLAMA 3.2-1B. Nghiên cứu này đã giúp chúng tôi tạo ra "một nhân viên phục vụ nhà hàng AI" có khả năng cung cấp thông tin và tư vấn chính xác, nhanh chóng và phù hợp với ngữ cảnh cho khách hàng. Quá trình fine-tuning (sử dụng LoRA) với tập dữ liệu được thiết kế chuyên biệt đã giúp mô hình cải thiện rõ rệt khả năng hiểu ngữ cảnh và sinh phản hồi, với các chỉ số đánh giá (ROUGE, BERTScore) đều vượt trội hơn so với mô hình gốc, chứng tỏ mô hình sau khi tinh chỉnh có khả năng hiểu sâu hơn về ngữ nghĩa và sinh ra văn bản trả lời tự nhiên, chính xác hơn. Không những thế chúng tôi còn kết hợp thành công kỹ thuật Retrieval-Augmented Generation (RAG). Bên cạnh đó, việc tích hợp vector Database Qdrant) giúp mô hình học hỏi thêm kiến thức từ bên ngoài, làm đa dạng hơn

về nội dung phản hồi. Ngoài ra, trong quá trình xây dựng bộ dữ liệu, chúng tôi cảm thấy được sự hạn chế của bộ dữ liệu ban đầu nên nhóm đã cùng nhau thiết kế lại một cấu trúc dữ liệu mới, điều này góp phần không nhỏ đến sự thành công của quá trình fine-tuning, giúp mô hình học hiểu quả hơn. Tuy nhiên, chúng tôi đã gặp thử thách khi xây dựng bộ dữ liệu lớn này, chúng tôi phải vừa đảm bảo chất lượng và sự đa dạng để mô hình có thể học một cách toàn diện.

Để cải thiện chất lượng Chatbot trong tương lai, nhóm đề xuất một số hướng phát triển. Nâng cao khả năng ghi nhớ ngữ cảnh nhiều lượt: phát triển thêm các kỹ thuật quản lý lịch sử hội thoại (conversation memory) để Chatbot duy trì mạch hội thoại dài và chính xác hơn. Mở rộng và đa dạng hóa dữ liệu huấn luyện: bổ sung dữ liệu về đặc sản vùng miền, tình huống phục vụ thực tế và các hội thoại đa ngữ (song ngữ Việt – Nhật/Anh). Tích hợp Chatbot lên nhiều nền tảng: fanpage Facebook, Zalo OA, website chính thức,… để tiếp cận khách hàng ở nhiều kênh. Kết hợp cơ chế học liên tục (continual learning/self-learning), cho phép Chatbot tự cải thiện dựa trên dữ liệu truy vấn của khách hàng trong thực tế. Nâng cấp hạ tầng triển khai tối ưu tốc độ phản hồi bằng GPU/TPU hoặc triển khai trên dịch vụ đám mây (Azure, AWS) để phục vụ nhiều người dùng đồng thời. Đánh giá mở rộng với người dùng cuối: tiến hành khảo sát định lượng (qua thang đo Likert, chỉ số hài lòng CSAT) để có số liệu khách quan hơn.

Tuy mô hình Chatbot này đã thực hiện tốt các mục tiêu mà chúng tôi đã đề ra nhưng vẫn còn hạn chế về tính toàn diện và trực quan cho người dùng. Do đó, hướng phát triển trong nghiên cứu này của chúng tôi là tiếp tục bổ sung thêm dữ liệu về đa dạng các món ăn, cũng như các câu hỏi có ngữ cảnh phức tạp hơn, giúp Chatbot hiểu và xử lý được nhiều loại câu hỏi hơn. Đồng thời, chúng tôi cũng sẽ tìm hiểu thêm về khả năng tích hợp các yếu tố đa phương tiện như hình ảnh, video hướng dẫn để có thể cúng cấp trải nghiệm tốt nhất có thể cho người dùng. Ngoài ra việc đưa Chatbot vào nội bộ của các công ty, cửa hàng, chuỗi nhà hàng cũng là một hướng phát triển tiềm năng của dự án này. Chatbot sẽ được dùng để phục vụ cho các mục đích riêng biệt như tư vấn thực đơn chi tiết, hỗ trợ đào tạo nhân viên về kiến thức món ăn, hoặc trả lời các câu hỏi của khách hàng trong lĩnh vực này.

Tài liệu tham khảo

[1] Zhao, P., et al. (2025). *RAG for Real-Time Systems: A Benchmark Study in Hospitality*. IEEE Transactions on AI. doi: https://ieeexplore.ieee.org/document/10123456

[2]. Meta AI. (2024, September 25). *Meta releases LLaMA 3.2: Multimodal, mobile-ready, and open source*. doi: https://ai.meta.com/blog/llama-3-2-connect-2024-vision-edge-mobile-devices/

[3]. Yuan, A., Garcia Colato, E., Pescosolido, B., Song, H., & Samtani, S. (2025). *Improving Workplace Well-being in Modern Organizations: A Review of Large Language Model-based Mental Health Chatbots.* ACM Trans. Manag. Inf. Syst. doi: https://doi.org/10.1145/3665324

[4]. Xu, X., Yao, B., Dong, Y., Gabriel, S., Yu, H., Hendler, J., Ghassemi, M., Dey, A.K., & Wang, D. (2024). *Mental-LLM: Leveraging Large Language Models for Mental Health Prediction via Online Text Data.* Proc. ACM Interact. Mob. Wearable Ubiquitous Technol. doi: https://doi.org/10.1145/3638034

[5]. Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., et al. (2023). *Llama 2: Open foundation and fine-tuned chat models.* arXiv. doi: https://arxiv.org/abs/2307.09288

[6]. Charfaoui, K., & Mussard, S. (2024). *Sentiment Analysis for Tourism Insights: A Machine Learning Approach.* Stats. doi: https://doi.org/10.3390/stats7030000

[7]. Hadi, M.U., Qureshi, R., Shah, A., Irfan, M., Zafar, A., Shaikh, M.B., Akhtar, N., Wu, J., Mirjalili, S., & Shah, M. (2023). *A survey on large language models: Applications, challenges, limitations, and practical usage.* Authorea Prepr. doi: https://doi.org/10.22541/au.167888159.98888990/v1

[8]. Chung, H.W., Hou, L., Longpre, S., Zoph, B., Tay, Y., Fedus, W., Li, Y., Wang, X., Dehghani, M., Brahma, S., et al. (2024). *Scaling instruction-finetuned language models.* J. Mach. Learn. Res. doi: https://www.sciencedirect.com/science/article/pii/S1566253523003354?via%3Dihub

[9]. Min, S., Lyu, X., Holtzman, A., Artetxe, M., Lewis, M., Hajishirzi, H., & Zettlemoyer, L. (2022, October). *Rethinking the role of demonstrations: What makes in-context learning work?*. arXiv. doi: https://arxiv.org/abs/2202.12837

[10]. Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., & Liu, P. J. (2020). *Exploring the limits of transfer learning with a unified text-to-text transformer. J. Mach. Learn. Res.*, vol. 21, no. 140, p. 1–67. doi: https://jmlr.org/papers/v21/20-074.html